


准确率接近，工具调用减少约 22%

ToolForge-RL · 同一 SFT 起点 · 2,619 道固定评测题

答案准确率

越高越好




差异 -0.04 个百分点

95% 置信区间: 准确率差异 [-1.22, +1.18] 个百分点; 调用降幅 [19.91%, 23.93%]。

平均工具调用次数

越低越好



减少 21.88%